

Hidden Markov Model (HMM) dan Algoritma Viterbi

MATA KULIAH: RTD BIOINFORMATIKA

- Pendekatan sebelumnya mencari gen dengan mengekstrak semua *ORF (Open Reading Frame)*.
- Metode ini kurang efisien untuk analisis DNA yang belum dianotasi.
- Diperlukan algoritma yang dapat menganalisis sekuens DNA secara langsung.

- Selain gen, DNA memiliki fitur lain seperti *CpG islands*^{*)}.
- Fitur tersebut tidak selalu memiliki batas jelas seperti *start codon* ($\mathcal{B}$) dan *stop codon* ($\mathcal{E}$).
- Karena itu diperlukan model statistik (pendekatan probabilistik) untuk menganalisis sekuens.

^{*)} [DEKM] Durbin, R., Eddy, S., Krogh, A., Mitchison, G.: *Biological Sequence Analysis*. Cambridge University Press (1998)

Two-Block Model

- Model memisahkan DNA menjadi dua bagian:
 1. gen: mengkode protein atau RNA
 2. intergenik: mengatur/memisahkan gen
- Setiap bagian dimodelkan dengan model Markov.
- Transisi antar model diizinkan.

State pada Model

- Contoh state gen:

$$A_g, C_g, G_g, T_g$$

- Contoh state intergenik:

$$A_{ig}, C_{ig}, G_{ig}, T_{ig}$$

Masalah dalam Model

- Satu sekuens DNA dapat dihasilkan oleh banyak jalur state.
- Contoh sekuens: $x^0 = ACCTG$
- Jalur state berbeda:

➤ $A_g C_{ig} C_g T_g G_{ig}$ dengan probabilitas x^0 :

$$p_{0A_g} p_{A_g C_{ig}} p_{C_{ig} C_g} p_{C_g T_g} p_{T_g G_{ig}} p_{G_{ig} 0} \quad (1)$$

➤ $A_{ig} C_{ig} C_g T_g G_g$ dengan probabilitas x^0 :

$$p_{0A_{ig}} p_{A_{ig} C_{ig}} p_{C_{ig} C_g} p_{C_g T_g} p_{T_g G_g} p_{G_g 0} \quad (2)$$

dapat menghasilkan sekuens yang sama yaitu $ACCTG$.

Konsep *Hidden*

- Sekuens DNA dapat diamati.
 - Namun jalur state yang menghasilkan sekuens tidak diketahui.
 - State tersebut disebut '*hidden*' (tersembunyi).

Hidden Markov Model (HMM)

- *Hidden Markov Model* adalah rantai Markov diskrit dengan state terbatas $G_1, G_2, \dots, G_N$.
- Setiap state memiliki probabilitas transisi p_{0j}, p_{ij}, p_{j0} dengan $i, j = 1, \dots, N$.
- Setiap state juga menghasilkan simbol dari alfabet tertentu.

Komponen HMM

1. State
2. Probabilitas transisi
3. Probabilitas emisi

Alfabet DNA biasanya: $\mathcal{Q} = \{A, C, G, T\}$

Probabilitas Sekuens

- Jika $x = x_1 \dots x_L$ adalah sekuens observasi Q dan $\pi = \pi_1 \dots \pi_L$ adalah jalur state


- Probabilitas pasangan dihitung dari transisi dan emisi

$$p(x, \pi) = p_{0\pi_1} q_{\pi_1}(x_1) p_{\pi_1\pi_2} q_{\pi_2}(x_2) \times \dots \times p_{\pi_{L-1}\pi_L} q_{\pi_L}(x_L) p_{\pi_L 0} \quad (3)$$

- Probabilitas total

$$P(x) = \sum_{\text{all } x \text{ of length } L} p(x, \pi) \quad (4)$$

The a priori connectivity.



State “g” dikaitkan dengan **gen** dan state “ig” dengan **intergenic** regions.

Masing-masing state diizinkan untuk menyatakan huruf dari alfabet DNA $\{A, C, G, T\}$ dengan probabilitas tertentu (namun, perlu dicatat bahwa model yang lebih realistis akan memisahkan **start codon** dari “ig” ke “g” dan **stop codon** dari “g” ke “ig”).

Penggunaan HMM dalam Bioinformatika

Decoding: menemukan jalur state tersembunyi yang paling mungkin, apakah sekuens sesuai dengan model pelatihan.

Metode yang digunakan: *Viterbi Algorithm*

Viterbi Algorithm

*Faster dynamic programming algorithm for determining all the most probable paths, called the **Viterbi Algorithm**.*

*Accordingly, the most probable paths are often called the **Viterbi paths**.*

Misalkan kita diberikan HMM yang rantai Markov dasarnya memiliki

- himpunan state $X = \{G_1, \dots, G_N\}$,
- end state
- probabilitas transisi $p_{0j}, p_{ij}, p_{j0}, i, j = 1, \dots, N$.
- $x = x_1 \dots x_L$ dari alfabet $\mathcal{Q}$

Didefinisikan:

$$v_k(1) = p_{0k} q_k(x_1) \quad (5)$$

dengan $k = 1, \dots, N$

$$v_k(i) = \max_{\pi_1, \dots, \pi_{i-1} \in X} p_{0\pi_1} q_{\pi_1}(x_1) p_{\pi_1\pi_2} q_{\pi_2}(x_2) \times \dots \times p_{\pi_{i-2}\pi_{i-1}} q_{\pi_{i-1}}(x_{i-1}) p_{\pi_{i-1}G_k} q_k(x_i)$$

dengan $i = 2, \dots, L$ dan $k = 1, \dots, N$

Jelas, kita memiliki

$$v_k(i + 1) = q_k(x_1) \max_{l=1, \dots, N} (v_l(i) p_{lk}) \quad (6)$$

dengan $i = 1, \dots, L - 1$ dan $k = 1, \dots, N$

Selanjutnya,

$$\max_{\text{all } \pi \text{ of length } L} P(x, \pi) = \max_{l=1, \dots, N} (v_l(L) p_{l0}) \quad (7)$$

dengan $i = 1, \dots, L - 1$ dan $k = 1, \dots, N$

Viterbi paths

Setiap *Viterbi path* dapat dipulihkan dengan prosedur penelusuran balik berikut:

- pilih $m_L \in \mathcal{V}(L)$,
- lalu pilih $m_{L-1} \in \mathcal{V}_{m_L}(L-1)$,
- lalu pilih $m_{L-2} \in \mathcal{V}_{m_{L-1}}(L-2)$, dan
- lanjutkan hingga kita memilih $m_1 \in \mathcal{V}_{m_2}(1)$.

Untuk **path** yang dihasilkan $\pi^* = 0G_{m_1}G_{m_2} \dots G_{m_L}0 = G_{m_1}G_{m_2} \dots G_{m_L}$ kita memiliki

$$P(x, \pi^*) = \max_{\text{all } \pi \text{ of length } L} P(x, \pi) \quad (8)$$

Contoh


Anggap HMM dengan $\mathcal{Q} = \{A, B\}$, yang rantai Markov dasarnya ditunjukkan pada Gambar dan probabilitas emisinya:

$$q_1(A) = 0.5, q_1(B) = 0.5$$

$$q_2(A) = 0.1, q_2(B) = 0.9$$

$$q_3(A) = 0.9, q_3(B) = 0.1$$

Misalkan $x = BAB$, temukan Viterbi path π^* .



Algoritma Viterbi

$$v_1(1) = p_{01} q_1(B) = 0.2 \cdot 0.5 = 0.1$$

$$v_2(1) = 0.3 \cdot 0.9 = 0.27$$

$$v_3(1) = 0.5 \cdot 0.1 = 0.05$$

$$v_k(1) = p_{0k} q_k(x_1) \quad (5)$$

dengan $k = 1, \dots, 3$

$$v_k(i+1) = q_k(x_1) \max_{l=1, \dots, N} (v_l(i) p_{lk}) \quad (6)$$

dengan $i = 2$ dan $k = 1, \dots, 3$

$$v_1(2) = q_1(A) \max_{l=1, \dots, 3} (v_l(1) p_{l1})$$

$$= q_1(A) \max\{v_1(1) p_{11}, v_2(1) p_{21}, v_3(1) p_{31}\}$$

$$= 0.5 \max\{(0.1 \cdot 0.3), (0.27 \cdot 0), (0.05 \cdot 0)\}$$


$$= 0.5 \cdot 0.1 \cdot 0.3 = 0.015 \rightarrow \mathbf{v_1(1) = \{1\}}$$

$$v_2(2) = 0.1 \max\{(0.1 \cdot 0.3), (0.27 \cdot 0.4), (0.05 \cdot 0.3)\}$$

$$= 0.1 \cdot 0.27 \cdot 0.4 = 0.0108 \rightarrow \mathbf{v_2(1) = \{2\}}$$

$$v_3(2) = 0.9 \max\{(0.1 \cdot 0.3), (0.27 \cdot 0.4), (0.05 \cdot 0.3)\}$$

$$= 0.9 \cdot 0.27 \cdot 0.4 = 0.0972 \rightarrow \mathbf{v_3(1) = \{2\}}$$



$$v_1(3) = q_1(B) \max_{l=1,\dots,3} (v_l(2)p_{l1})$$

$$\begin{aligned} &= q_1(B) \max\{v_1(2)p_{11}, v_2(2)p_{21}, v_3(2)p_{31}\} \\ &= 0.5 \max\{(0.015 \cdot 0.3), (0.0108 \cdot 0), (0.0972 \cdot 0)\} \\ &= 0.5 \cdot 0.015 \cdot 0.3 = 0.000225 \rightarrow \mathbf{v_1(2) = \{1\}} \end{aligned}$$

$$v_k(i+1) = q_k(x_1) \max_{l=1,\dots,N} (v_l(i)p_{lk}) \quad (6)$$


dengan $i = 3$ dan $k = 1, \dots, 3$

$$\begin{aligned} v_2(3) &= 0.9 \max\{(0.015 \cdot 0.3), (0.0108 \cdot 0.4), (0.0972 \cdot 0.3)\} \\ &= 0.9 \cdot 0.0972 \cdot 0.3 = 0.026244 \rightarrow \mathbf{v_2(2) = \{3\}} \end{aligned}$$

$$\begin{aligned} v_3(3) &= 0.1 \max\{(0.015 \cdot 0.3), (0.0108 \cdot 0.4), (0.0972 \cdot 0.3)\} \\ &= 0.1 \cdot 0.0972 \cdot 0.3 = 0.002916 \rightarrow \mathbf{v_3(2) = \{3\}} \end{aligned}$$

$$P(x, \pi^*) = \max_{l=1,\dots,3} (v_l(3)p_{l0})$$

$$\begin{aligned} &= \max\{v_1(3)p_{10}, v_2(3)p_{20}, v_3(3)p_{30}\} \\ &= \max\{(0.000225 \cdot 0.1), (0.026244 \cdot 0.2), (0.002916 \cdot 0.4)\} = 0.002916 \cdot 0.2 \\ &= 0.0005832 \rightarrow \mathbf{v(3) = \{2\}} \end{aligned}$$



Setiap *Viterbi path* dengan penelusuran balik berikut:

- pilih $\mathcal{V}(3) = \{2\}$ yaitu path $G_2 \rightarrow E$,
- lalu pilih $\mathcal{V}_{m_3}(2) = \{3\}$ yaitu path $G_3 \rightarrow G_2 \rightarrow E$,
- lanjutkan hingga kita memilih $\mathcal{V}_{m_2}(1) = \{2\}$ yaitu path $G_2 \rightarrow G_3 \rightarrow G_2 \rightarrow E$.

Jadi, untuk $x = BAB$, temukan Viterbi path $\pi^* = G_2 G_3 G_2$ ■


Latihan 3.6

Anggap HMM dengan $\mathcal{Q} = \{A, B\}$, yang rantai Markov dasarnya ditunjukkan pada Gambar dan probabilitas emisinya:

$$q_1(A) = 0.5, q_1(B) = 0.5$$

$$q_2(A) = 0.9, q_2(B) = 0.1$$

Misalkan $x = ABB$, temukan Viterbi path π^* .



Algoritma Viterbi

$$v_1(1) = p_{01} q_1(A) = 0.8 \cdot 0.5 = 0.04$$

$$v_2(1) = 0.2 \cdot 0.9 = 0.18$$

$$v_k(1) = p_{0k} q_k(x_1) \quad (5)$$

dengan $k = 1, 2$

$$v_1(2) = q_1(A) \max_{l=1,2} (v_l(1) p_{l1})$$

$$v_k(i+1) = q_k(x_1) \max_{l=1,\dots,N} (v_l(i) p_{lk}) \quad (6)$$

dengan $i = 2$ dan $k = 1, 2$

$$= q_1(A) \max\{v_1(1) p_{11}, v_2(1) p_{21}\}$$


$$= 0.5 \max\{(0.04 \cdot 0.2), (0.18 \cdot 0)\}$$

$$= 0.5 \cdot 0.04 \cdot 0.2 = 0.0040 \rightarrow \mathbf{v_1(1) = \{1\}}$$

$$v_2(2) = 0.9 \max\{(0.04 \cdot 0.6), (0.18 \cdot 0.9)\}$$

$$= 0.9 \cdot 0.18 \cdot 0.9 = 0.1458 \rightarrow \mathbf{v_2(1) = \{2\}}$$

$$q_1(A) = 0.5, q_1(B) = 0.5$$
$$q_2(A) = 0.9, q_2(B) = 0.1$$



$$v_k(i+1) = q_k(x_1) \max_{l=1, \dots, N} (v_l(i) p_{lk}) \quad (6)$$

dengan $i = 3$ dan $k = 1, 2$

$$v_1(2) = q_1(B) \max_{l=1,2} (v_l(2) p_{l1})$$

$$= q_1(B) \max\{v_1(2) p_{11}, v_2(2) p_{21}\}$$

$$= 0.5 \max\{(0.004 \cdot 0.2), (0.1458 \cdot 0)\}$$

$$= 0.5 \cdot 0.004 \cdot 0.2 = 0.00040 \rightarrow \mathbf{v_1(1) = \{1\}}$$

$$v_2(2) = 0.1 \max\{(0.004 \cdot 0.6), (0.1458 \cdot 0.9)\}$$

$$= 0.1 \cdot 0.1458 \cdot 0.9 = 0.013122 \rightarrow \mathbf{v_2(1) = \{2\}}$$

$$P(x, \pi^*) = \max_{l=1,2} (v_l(3) p_{l0})$$


$$= \max\{v_1(3) p_{10}, v_2(3) p_{20}\}$$

$$= \max\{(0.0004 \cdot 0.2), (0.013122 \cdot 0.1)\}$$

$$= 0.013122 \cdot 0.1 = 0.0013122 \rightarrow \mathbf{v(3) = \{2\}}$$

$$q_1(A) = 0.5, q_1(B) = 0.5$$

$$q_2(A) = 0.9, q_2(B) = 0.1$$



Setiap *Viterbi path* dengan penelusuran balik berikut:

- pilih $\mathcal{V}(3) = \{2\}$ yaitu path $G_2 \rightarrow E$,
- lalu pilih $\mathcal{V}_{m_3}(2) = \{2\}$ yaitu path $G_2 \rightarrow G_2 \rightarrow E$,
- lanjutkan hingga kita memilih $\mathcal{V}_{m_2}(1) = \{2\}$ yaitu path $G_2 \rightarrow G_2 \rightarrow G_2 \rightarrow E$.

Jadi, untuk $x = AAB$, temukan Viterbi path $\pi^* = G_2G_2G_2$ ■

Referensi:

Isaev, A. **Introduction to Mathematical Methods in Bioinformatics.**
Springer-Verlag Berlin Heidelberg (2006)